

Tópico: collaborative filtering and et al in latent space

Resumen Detallado sobre Sistemas de Recomendación

Introducción a los Sistemas de Recomendación

Los sistemas de recomendación (RS, por sus siglas en inglés) son herramientas importantes en la personalización del contenido digital para los usuarios. Nacen de la necesidad de filtrar el gran volumen de información disponible en la web y proporcionar a cada usuario recomendaciones personalizadas basadas en sus preferencias. Este resumen se centra en un artículo que ofrece una visión general de los sistemas de recomendación, destacando la evolución del campo, las metodologías utilizadas, y los desafíos y áreas futuras de investigación.

Tipos de Sistemas de Recomendación

Existen varios tipos de sistemas de recomendación, entre los que destacan:

1. ****Filtración Colaborativa (CF):**** Esta técnica utiliza la experiencia de un grupo amplio de usuarios para recomendar ítems. Se basa en el supuesto de que si dos personas coinciden en sus preferencias con respecto a ciertos artículos, probablemente coincidirán en otros. La filtración colaborativa se divide en métodos basados en memoria y en modelos.
2. ****Basados en Contenido:**** Estos sistemas recomiendan ítems similares a aquellos que el usuario ha mostrado interés previamente, centrándose en las características de los elementos.

3. ****Demográficos:**** Utilizan características demográficas de los usuarios como edad, género o nacionalidad para realizar recomendaciones más precisas.
4. ****Híbridos:**** Combinan diferentes técnicas de recomendación para mejorar la calidad y precisión de las recomendaciones.

Evolución de los Sistemas de Recomendación

Los sistemas de recomendación han evolucionado considerablemente:

- ****Fase Tradicional (Web 1.0):**** Enfoque en la recolección de preferencias de usuarios a través de métodos como encuestas explícitas y el monitoreo de comportamiento.
- ****Fase Social (Web 2.0):**** La integración de la información social permitió que las recomendaciones fueran más precisas al utilizar relaciones sociales y datos de redes sociales.
- ****Fase del Internet de las Cosas (IoT):**** El futuro de los sistemas de recomendación está en la incorporación de datos del IoT, como señales de salud en tiempo real y ubicaciones GPS, para hacer recomendaciones altamente personalizadas.

Desafíos Actuales y Futuros

A pesar de los avances, los sistemas de recomendación aún enfrentan varios desafíos:

- ****Problema de**

Documentos Clave:

recommender system survey knowledgebased system recommender system survey knowledgebased system recommender system survey knowledgebased system recommender system recommender system recommender system survey j bobadilla f ortega hernando gutiérrez universidad politécnica de ctra de valencia km spain r c l e n f article history received october received revised form march accepted march available online april keywords recommender system collaborative filtering similarity measure evaluation metric prediction recommendation hybrid social internet thing coldstart b r c recommender system developed parallel web initially demo graphic contentbased collaborative filtering currently system incorporating social infor mation future use implicit local personal internet thing article provides overview recommender system well collaborative filtering method algorithm also explains evolution provides original classification system iden tifies area future implementation develops certain area selected past present future importance elsevier bv right reserved recommender system rss collect prefer ences user set item eg movie song book joke gadget application website travel destination elearning material acquired explicitly typically collecting user rating implicitly typically monitoring user behavior song heard application downloaded web site visited book read r may use demo graphic feature user like age nationality gender social like follower followed twit post commonly used web growing tend towards use infor mation internet thing eg gps location rfid realtime health signal r make use different source providing user prediction recommendation item try balance factor like accuracy novelty dispersity stability recommendation collaborative filtering cf method play important role recommendation although often used along filterning technique like contentbased knowledgebased social one cf way human made decision throughout history besides experience also base decision experience knowledge reach

Tópico: collaborative filtering and et al in latent space

El artículo titulado "Neural Group Recommendation: Probabilistic Semantic Aggregation" aborda un enfoque innovador en el campo de las recomendaciones de grupos de usuarios, utilizando técnicas avanzadas de aprendizaje profundo y agregación semántica probabilística. Este documento fue elaborado por Jorge Duenaslerin, Raúl Laracabrera, Fernando Ortega y Jesús Bobadilla, quienes propusieron un modelo que se centra en superar los desafíos inherentes al subcampo de las recomendaciones para grupos dentro de los sistemas de recomendación.

Contexto y Problema Planteado

Los sistemas de recomendación se han convertido en una herramienta clave bajo el paraguas de la inteligencia artificial debido a su capacidad para personalizar experiencias en servicios como Amazon, Netflix, Spotify, entre otros. Estos sistemas suelen trabajar sobre la base de la filtración colaborativa, la cual se apoya en técnicas de factorización de matrices para generar recomendaciones rápidas y precisas. Sin embargo, el artículo señala las limitaciones de la factorización de matrices tradicionales, específicamente su dificultad para detectar relaciones complejas no lineales entre las calificaciones de entrada, las cuales son cruciales para el proceso de recomendación.

Enfoque de la Investigación

Los autores han desarrollado un modelo de recomendación de grupos que se basa en una nueva estrategia de agregación para usuarios múltiples: la codificación de entidades virtuales mediante vectores multihot que se introducen en una red neuronal. Esta estrategia no solo permite una agregación más coherente y efectiva de las

preferencias del grupo, sino que también facilita la generalización de las recomendaciones grupales a partir de predicciones individuales.

La arquitectura propuesta ofrece una ventaja significativa al permitir que las recomendaciones grupales sean generadas a partir de un modelo de red neuronal previamente entrenado con calificaciones individuales, eliminando así la necesidad de tener disponibles conjuntos de datos preclasificados por grupos de usuarios y de realizar entrenamientos distintos para usuarios individuales y grupos. Este enfoque no solo simplifica el proceso, sino que también evita la necesidad de mantener múltiples modelos, lo cual es logísticamente ventajoso.

Resultados Experimentales

El artículo destaca que la arquitectura propuesta fue probada con tres conjuntos de datos representativos de filtración colaborativa. Los resultados demostraron una mejora en la precisión de las recomendaciones, al compararse con los métodos contemporáneos del estado del arte. Este aumento en la precisión es atribuible a la capacidad del modelo para capturar con éxito relaciones

Documentos Clave:

neural group recommendation probabilistic semantic aggregation neural group recommendation probabilistic semantic aggregation neural group recommendation probabilistic semantic aggregation group recommender collaborative filtering aggregation model deep learning group recommender collaborative filtering aggregation model deep learning original article neural group recommendation probabilistic semantic aggregation jorge duenaslerin raul laracabrera fernando ortega jesus bobadilla received july accepted february published online march author exclusive

licence springerverlag london ltd part springer nature recommendation group user
challenging subfield recommendation system key concept make aggregation set user
individual entity ranked recommendation list virtual user multihot input vector encoding
proposes innovative strategy aggregation made multihot vector feed neural network
aggregation provides probabilistic semantic resulting input vector feed able
conveniently generalize group recommendation individual prediction furthermore
proposed architecture group recommendation obtained simply feedforwarding
pretrained individual rating without need obtain datasets containing group user without
need running two separate training individual group also avoids maintaining two
different model support individual group learning experiment tested proposed
architecture three representative collaborative filtering datasets series baseline result
show suitable accuracy improvement compared state art keywords group recommender
collaborative filtering aggregation model deep learning personalization one fields
artificial intelligence ai greater impact life individual find multitude service provide u
personalized choice news video song restaurant clothes travel etc relevant tech
company make extensive use personalization service amazon netflix spotify tripadvisor
google tiktok etc company generate personalized recommendation recommender r
application rec ommender r provides user personal ized pr

Tópico: collaborative filtering and et al in latent space

El artículo revisado aborda un sistema basado en conocimiento que se especializa en la creación de conjuntos de datos sintéticos para sistemas de recomendación mediante el uso de redes generativas adversarias (GANs). El objetivo principal de este enfoque es mejorar la calidad y la representatividad de los datos utilizados para entrenar, validar y probar sistemas de recomendación, más específicamente en el subcampo de filtrado colaborativo.

Los sistemas de recomendación han demostrado ser una herramienta poderosa dentro de la inteligencia artificial, especialmente con su creciente aplicación en redes sociales y grandes corporaciones como Netflix, Spotify, Tripadvisor, entre otras. Estos sistemas buscan sugerir a los usuarios productos, servicios o contenidos que puedan ser de interés basado en diversas técnicas de filtrado.

Uno de los principales desafíos a los que se enfrentan los sistemas de recomendación es la necesidad de conjuntos de datos ricos y diversos. Si bien existen conjuntos de datos reales, a menudo son insuficientes o limitados en representatividad. Por tanto, el artículo propone la generación de datos sintéticos como una solución eficiente y adaptable, utilizando redes generativas adversarias. Las GANs son redes neuronales que consisten en un generador que crea nuevas muestras y un discriminador que evalúa su autenticidad. Este proceso iterativo permite la mejora continua en la generación y autenticidad de los datos sintéticos producidos.

El estudio describe cómo la parametrización cuidadosa y la elección del número de usuarios y elementos a incluir permiten personalizar el equilibrio entre precisión y robustez en los modelos de recomendación. Además, enfatiza la importancia de convertir muestras generadas densas y continuas en las muestras discretas y esparsas

necesarias para crear conjuntos de datos adecuados para los métodos tradicionales de filtrado colaborativo.

La arquitectura propuesta apuesta por una técnica llamada DeepMF para extraer representaciones densas de usuarios y elementos, lo que facilita una conversión eficiente y precisa de los datos generados. El proceso incluye un paso de clustering, crucial para manejar la transición entre los datos generados por el GAN y los que son útiles para la recomendación.

Los resultados presentados por los autores muestran que los conjuntos de datos generados presentan una distribución adecuada y una calidad que es comparable a la de los conjuntos de datos fuente, ofreciendo así una herramienta valiosa para la investigación y el desarrollo de futuros sistemas de recomendación. De hecho, los experimentos realizados utilizando tres diferentes conjuntos de datos de origen demuestran la efectividad de esta metodología.

Los

Documentos Clave:

knowledgebased system creating synthetic datasets collaborative filtering recommender system generative adversarial network knowledgebased system creating synthetic datasets collaborative filtering recommender system generative adversarial network knowledgebased system creating synthetic datasets collaborative filtering recommender system generative adversarial network recommender system recommender system knowledgebased system available online september author published elsevier bv open access article cc license <http://creativecommons.org/licenses/by-content/list/available/sciencedirect> knowledgebased system journal homepage

wwwelseviercomlocateknosys creating synthetic datasets collaborative filtering recommender system generative adversarial network jesús bobadilla abraham gutiérrez raciel yera b luis martínez b departamento de sistemas informáticos etsi sistemas informáticos universidad politécnica de c alan turing sn spain b departamento de informática universidad jaén jaén spain r c l e n f keywords recommender system generative adversarial network deep learning collaborative filtering b r c research education machine learning requires diverse representative open datasets contain sufficient sample handle necessary training validation testing task currently recommender system area includes large number subfields accuracy beyondaccuracy quality measure continuously improved feed research variety necessary convenient reinforce existing datasets synthetic one proposes generative adversarial network ganbased generate collaborative filtering datasets parameterized way selecting preferred number user item sample stochastic variability parameterization performed regular gans gan fed dense short continuous embedding representation item user instead sparse large discrete vector ensure fast accurate learning compared traditional large sparse input vector proposed architecture includes deepmf extract dense user item embeddings clustering process convert dense gan generated samp

Tópico: collaborative filtering and et al in latent space

El contenido analizado se centra principalmente en la evaluación integral de un modelo de factorización de matrices para sistemas de recomendación basado en filtrado colaborativo. Este modelo es parte de la inteligencia artificial, específicamente diseñado para la personalización de experiencias de usuario, y su objetivo es proporcionar recomendaciones precisas de artículos como películas, libros, música, viajes, entre otros.

Evaluación y Contexto del Estudio

Este estudio, presentado en el artículo titulado "Comprehensive Evaluation of Matrix Factorization Model for Collaborative Filtering Recommender Systems" y publicado en el ****International Journal of Interactive Multimedia and Artificial Intelligence****, aborda los desafíos y oportunidades presentados por los modelos de factorización de matrices en el ámbito de los sistemas de recomendación. La investigación es una colaboración entre autores de instituciones como la Universidad Politécnica de Madrid y la Universidad la Salle, México.

A lo largo del estudio, se evaluaron seis modelos representativos de factorización de matrices utilizando cuatro conjuntos de datos diferentes de filtrado colaborativo. El objetivo era medir no solo la precisión estándar de las recomendaciones (predicción), sino también otros aspectos cualitativos como novedad y diversidad, que son igualmente fundamentales para mejorar la experiencia del usuario.

Resultados y Conclusiones

Los resultados mostraron que los modelos de factorización de matrices son

particularmente convenientes por su simplicidad y la calidad de las predicciones, lo cual es esencial para la calidad del sistema de recomendaciones. Además, se puso en relieve la necesidad de incluir medidas de novedad y diversidad en las recomendaciones para aumentar su valor percibido.

Un elemento esencial del estudio es la metáfora del factor oculto, la cual es utilizada para explicar la adecuación de las recomendaciones. Esta técnica permite asignar interpretaciones semánticas a factores que no son explícitamente observables desde los datos del usuario, lo cual facilita la creación de recomendaciones más personalizadas y relevantes.

Implicaciones y Aplicaciones

Los sistemas de recomendación, como los discutidos en este estudio, son fundamentales en plataformas comerciales como Amazon, Spotify, y Netflix. Todos estos sistemas utilizan alguna variación de filtrado colaborativo, el cual se basa en encontrar patrones de consumo colectivo entre usuarios para predecir qué podría interesar a otros usuarios con comportamientos similares.

Además de la precisión, el artículo discute la importancia de la confianza en las relaciones entre usuarios, especialmente relevante en ambientes donde los sistemas de recomendación pueden beneficiarse de gráficos de relaciones

Documentos Clave:

comprehensive evaluation matrix factorization model collaborative filtering
recommender system keywords comprehensive evaluation matrix factorization model
collaborative filtering recommender system r comprehensive evaluation matrix

factorization model collaborative filtering recommender system keywords
comprehensive evaluation matrix factorization model collaborative filtering
recommender system r comprehensive evaluation matrix factorization model
collaborative filtering recommender system keywords comprehensive evaluation matrix
factorization model collaborative filtering recommender system r nan nan see
discussion stats author profile publication <https://www.researchgate.net/publication>
comprehensive evaluation matrix factorization model collaborative filtering
recommender system article international journal interactive multimedia artificial
intelligence january doi ijimai citation read author jesus bobadilla universidad
politécnica de publication citation see profile jorge dueñaslerín comunidad de
publication citation see profile fernando ortega universidad politécnica de publication
citation see profile abraham gutierrez universidad la salle méxico publication citation
see profile content following page uploaded jorge dueñaslerín july user requested
enhancement downloaded file corresponding author email address
jesusbobadillaupmes j bobadilla jorgedlalumnosupmes j dueñaslerín
fernandoortegaupmes f ortega abrahamgutierrezupmes gutierrez please cite article
press j bobadilla j dueñaslerín f ortega gutierrez comprehensive evaluation matrix
factorization model collaborative filtering recommender system international journal
interactive multimedia artificial intelligence <http://dx.doi.org/ijimai> keywords collaborative
filtering matrix factorization recommender system matrix factorization model core
current commercial collaborative filtering recommender system tested six
representative matrix factorization model four collaborative filtering datasets
experiment tested variety a

Tópico: collaborative filtering and et al in latent space

El documento que se resume discute un modelo de recomendación basado en filtrado colaborativo, que utiliza un modelo variacional profundo para mejorar la precisión y robustez de las recomendaciones. Esta técnica incorpora la stocasticidad necesaria en el espacio latente y aborda problemas de esparcimiento en los sistemas de recomendación, un desafío frecuente debido a la naturaleza dispersa de los datos de usuario-artículo. A través de técnicas como la factorización de matrices profundas y el uso de autoencoders variacionales, se presenta una técnica avanzada que va más allá de los enfoques tradicionales de aprendizaje automático para filtrado colaborativo.

El uso de aprendizaje profundo ofrece ventajas significativas sobre los métodos tradicionales, como los modelos de vecindad o la factorización de matrices probabilísticas. Particularmente, el modelo propuesto integra el concepto de autoencoders variacionales para crear un espacio latente robusto y continuo, lo que permite manejar mejor la variación de datos inherentemente escasos en los sistemas de recomendación.

Este framework se basa en la opera con técnicas avanzadas de aprendizaje automático que enriquecen el filtrado colaborativo variacional al inyectar una stocasticidad en el espacio latente del modelo neural, lo que resulta en mejoras notables en términos de precisión y previsibilidad de las recomendaciones. Este enfoque demuestra ser superior en comparación con otros modelos de factorización de matrices como PMF, NMF, y BNM, al destacar no sólo por su precisión sino también por su flexibilidad y adaptabilidad en diversos contextos de sistemas de recomendación.

Los experimentos realizados en el estudio se llevaron a cabo en cuatro conjuntos de datos representativos, utilizando tres medidas de calidad para demostrar la efectividad

y superioridad del modelo propuesto respecto a los sistemas de recomendación de última generación. Estos experimentos evidencian que la introducción de stocasticidad mediante el enfoque variacional mejora los resultados globales de filtrado colaborativo.

El ámbito de aplicación del sistema de recomendación es amplio, abarcando desde plataformas de streaming como Spotify y Netflix, hasta comercio electrónico como Amazon y servicios turísticos como TripAdvisor. En cada caso, el objetivo principal es modelar y predecir la recomendación de ítems para usuarios individuales, mejorando la calidad de las sugerencias que se presentan al usuario final.

Por tanto, el documento no solo explora el potencial y las capacidades del modelo variacional profundo aplicado al filtrado colaborativo, sino que

Documentos Clave:

deep variational model collaborative filteringbased recommender system deep variational model collaborative filteringbased recommender system deep variational model collaborative filteringbased recommender system recommender system collaborative filtering variational enrichment deep learning recommender system collaborative filtering variational enrichment deep learning original article deep variational model collaborative filteringbased recommender system jesus bobadilla fernando ortega abraham gutierrez ngel gonzalezprietoreceived september accepted november published online december author deep learning provides accurate collaborative filtering model improve recommender result deep matrix factorization related collaborative neural network state art field nevertheless model lack necessary stochasticity create robust continuous structured latent space variational autoencoders exhibit hand augmentation variational autoencoder provide accurate result collaborative filtering field due high sparsity recommender system proposed model

apply variational concept inject stochasticity latent space deep architecture introducing variational technique neural collaborative filtering field depend particular used generate latent representation way applied plugin current future specific model proposed model tested four representative open datasets three different quality measure stateoftheart baseline result show superiority proposed scenario variational enrichment exceeds injected noise effect additionally framework provided enable reproducibility conducted experiment keywords recommender system collaborative filtering variational enrichment deep learning recommender system rss artificial intelligence field provides method model predict recommend item user eg films person ecom merce product costumer service company quality service qos internet thing iot device etc current popular rss spotify netflix tripadvisor amazon etc rss usually categorized attending filtering strategy mainly demo graphic

Tópico: synthetic datasets and mode collapse in source

Este contenido describe una arquitectura basada en Generative Adversarial Networks (GAN) utilizando la distancia de Wasserstein para generar conjuntos de datos sintéticos que mejoran los sistemas de recomendación basados en filtrado colaborativo. La técnica, denominada WGAN-RS, representa un avance en el campo de los sistemas de recomendación, que son herramientas clave para empresas como Spotify, Netflix, Tripadvisor, Amazon y Google, que dependen de estos sistemas para mejorar la experiencia del usuario al sugerir productos o servicios que probablemente les interesen.

Contexto y Relevancia

El uso de sistemas de recomendación se está expandiendo rápidamente debido a su capacidad para personalizar el contenido que se ofrece a los usuarios, manteniéndolos así enganchados a los servicios. Estos sistemas se basan en diferentes técnicas de filtrado, incluyendo el filtrado colaborativo, que utiliza las preferencias de usuarios similares para hacer recomendaciones. Sin embargo, uno de los desafíos es la necesidad de grandes cantidades de datos de usuario para mejorar la precisión de estas recomendaciones.

Propuesta de Solución

La propuesta presentada en el artículo utiliza una arquitectura basada en GAN, un tipo de red neuronal que consta de dos modelos que compiten entre sí: un generador que crea datos falsos y un discriminador que intenta diferenciar entre los datos reales y los generados. La arquitectura propuesta, WGAN-RS, aplica el concepto de Wasserstein a GAN para reducir colapsos de modo, aumentar el tamaño de los conjuntos de datos

sintéticos, mejorar la distribución de las calificaciones y mantener la capacidad de ajustar el número de usuarios y artículos de manera deseada.

Beneficios del Enfoque

- **Generación de Conjuntos de Datos Sintéticos**: La arquitectura propuesta permite la creación de perfiles falsos densos y continuos en un espacio latente, lo que es una mejora con respecto a muestras discretas grandes y esparcidas utilizadas en modelos anteriores.
- **Escalabilidad**: A través de la generación de conjuntos de datos sintéticos, permite simular diferentes escenarios con variaciones masivas en el tamaño del conjunto de datos, el número de usuarios y elementos.
- **Mejora en la Distribución de Calificaciones**: Con el uso de la distancia de Wasserstein, se mejora la homogeneidad y distribución de las calificaciones dentro de los datos sintéticos generados, lo cual es crucial para un sistema de recomendación eficaz.

Implicaciones

Documentos Clave:

wasserstein ganbased architecture generate collaborative filtering synthetic datasets
wasserstein ganbased architecture generate collaborative filtering synthetic datasets
wasserstein ganbased architecture generate collaborative filtering synthetic datasets
wganrs generative adversarial network recommender system wasserstein distance
synthetic wganrs generative adversarial network recommender system wasserstein
distance synthetic <https://doi.org/> wasserstein ganbased architecture generate
collaborative filtering synthetic datasets jesús bobadilla abraham gutiérrez accepted

february author currently generative application reshaping different field art computer vision speech processing natural language computer science personalization area increasingly relevant since large company spotify netflix tripadvisor amazon google use recommender system rational expect generative learning increasingly used improve current recommender system proposed generate synthetic recommender datasets used test recommendation performance accuracy company different simulated scenario large increase dataset size number user number item specifically improvement stateoftheart proposed applying wasserstein concept generative adversarial network recommender system ganrs seminal generate synthetic datasets result show proposed reduces mode collapse increase size synthetic datasets improves rating distribution maintains potential choose desired number user number item starting size dataset baseline ganrs proposed wassersteinbased wganrs deep learning architecture generate fake profile dense short continuous embeddings latent space instead sparse large discrete raw sample previous gan model used source enable reproducibility python kera code provided open repository along synthetic datasets generated test proposed architecture <https://github.com/jesusbobadillaganrsgit> keywords wganrs generative adversarial network recommender system wasserstein distance synthetic datasets collaborative filtering recommen