

## **Tópico: et al and collaborative filtering in bobadilla et**

Documento: Recommender systems survey.pdf

El documento de Bobadilla et al. ofrece un profundo análisis sobre los sistemas de recomendación, enfatizándose en la evolución del filtrado colaborativo y su integración en sistemas modernos. El filtrado colaborativo (CF) es fundamental para los sistemas de recomendación, ya que permite tomar decisiones basadas no solo en la experiencia personal, sino también en el conocimiento acumulado de un grupo extenso. Aunque a menudo se utiliza junto con otras técnicas como contenido y conocimiento basado, y últimamente, con técnicas sociales, su importancia sigue siendo crucial.

El artículo discute cómo los sistemas de recomendación han evolucionado desde enfoques simples basados en datos demográficos y de contenido hasta incorporar información social y del Internet de las Cosas (IoT), destacando la tendencia hacia la personalización y el uso de información implícita del usuario, como la conducta de navegación.

Bobadilla et al. destacan la importancia de las técnicas híbridas que combinan diferentes métodos para mejorar la precisión, la novedad, la dispersión y la estabilidad de las recomendaciones. Además, señalan el creciente interés por técnicas de filtrado social debido a la proliferación de redes sociales, lo que ha impulsado la popularidad de las recomendaciones basadas en el vecindario. Con el tiempo, el papel del CF en los sistemas de recomendación ha expandido, reflejando su adaptación a las nuevas tecnologías y necesidades del usuario.

## **Tópico: latent space and group in synthetic datasets**

Documento: Deep variational models for collaborative filtering-based recommender systems.pdf

El documento aborda el uso del espacio latente y su relevancia en la generación de datasets sintéticos, principalmente enfocado en sistemas de recomendación basados en filtrado colaborativo utilizando autoencoders variacionales profundos. Estos modelos intentan superar las limitaciones de la factorización matricial clásica (como PMF, NMF y BNM) introduciendo la variabilidad requerida en el espacio latente, lo cual mejora significativamente la precisión del filtrado colaborativo en entornos de alta dispersión de datos, característicos de los sistemas de recomendación actuales como los de Spotify, Netflix y Amazon.

El uso de autoencoders variacionales ayuda a crear un espacio latente más robusto y continuo, permitiendo una representación de datos más efectiva y aumentando la precisión de las recomendaciones. El modelo propuesto por los autores se ha probado en cuatro datasets representativos, mostrando su superioridad en comparación con enfoques tradicionales. Además de considerar la estructura latente, el modelo también es flexible y permite su integración con arquitecturas basadas en aprendizaje profundo, ofreciendo mejoras en infraestructuras de sistemas de recomendación actuales. La inyección de estocasticidad en el espacio latente se presenta como un elemento central para mejorar la robustez de las predicciones. Este enfoque también está diseñado para ser reproducible, permitiendo así que otros investigadores apliquen y amplíen el trabajo realizado.

## **Tópico: nmf bnmf and hidden factor in number**

### **Comprehensive Evaluation of Matrix Factorization Models for Collaborative Filtering Recommender**

El texto mencionado realiza una discusión sobre los modelos de factorización de matrices, específicamente en el contexto de los sistemas de recomendación colaborativa. En este ámbito, el texto menciona cómo la factorización de matrices se encuentra en el núcleo de los sistemas comerciales de recomendación basados en filtrado colaborativo. Entre las técnicas empleadas se destacan la factorización de matrices no negativa (NMF, por sus siglas en inglés) y variaciones como BNMF, que buscan interpretar y manejar factores ocultos al proporcionar las recomendaciones.

Los modelos de factorización de matrices, incluido el NMF, se evalúan en una variedad de conjuntos de datos de filtrado colaborativo para medir su precisión, así como aspectos de novedad, diversidad y capacidad para explicar las recomendaciones. Estos métodos intentan descubrir patrones de comportamiento de usuario y características de ítems, permitiendo que los sistemas de recomendación presenten sugerencias personalizadas y relevantes para los usuarios. En resumen, los factores ocultos tratados a través de NMF y similares, ofrecen una manera efectiva de identificar relaciones subyacentes en grandes volúmenes de datos de votaciones y consumos.

La capacidad de estos modelos para capturar la esencia de las preferencias y comportamientos de los usuarios se traduce en recomendaciones más alineadas con las expectativas del usuario, mejorando así la experiencia y eficacia del sistema de recomendación.

## **Tópico: number and synthetic datasets in random noise**

ating synthetic datasets for collaborative filtering recommender systems using generative adversarial

El texto se centra en la creación de conjuntos de datos sintéticos en sistemas de recomendación, utilizando redes generativas antagónicas (GAN) en el contexto de ruido aleatorio. Estos sistemas se benefician de datasets diversificados, esenciales para entrenar, validar y probar modelos de aprendizaje automático. Actualmente, en el ámbito de los sistemas de recomendación, se utiliza una amplia gama de datasets que abarcan desde subcampos relacionados hasta métricas de calidad más allá de la precisión. La propuesta central involucra el uso de GAN para generar datasets específicos para filtrado colaborativo.

Las GAN permiten crear muestras predictivas al introducir variabilidad estocástica mediante la parametrización por el número deseado de usuarios y elementos. En lugar de utilizar vectores grandes y dispersos, estas redes trabajan con representaciones densas y continuas de usuarios y artículos, lo que optimiza el aprendizaje en términos de velocidad y precisión. Esto se contrapone a los métodos tradicionales que suelen manejar datos más dispersos.

El proceso implica una arquitectura que extrae embebidos densos de usuarios y elementos y, a través de procesos de agrupamiento, transforma estas muestras en representaciones discretas y esparcidas, cumpliendo con los requisitos necesarios para datasets sintéticos. Los resultados obtenidos de diferentes fuentes muestran que los datos generados mantienen una distribución y calidad esperadas, siendo comparables a los datasets originales. La disponibilidad del código fuente facilita a investigadores en el ámbito de los sistemas de recomendación explorar estas innovaciones.