

Tópico: bnmf urp and epoch epoch in biasedmf bemf

: Comprehensive Evaluation of Matrix Factorization Models for Collaborative Filtering Recommender Systems

El texto aborda modelos de factorización de matrices (MF) en sistemas de recomendación colaborativa, destacando dos enfoques: la Factorización de Matrices Neutras Basada en Usuario (bnmf) y la Epoch Epoch en BiasedMF Bemf. Estos modelos son esenciales en los sistemas de recomendación actuales, ya que ayudan a personalizar las recomendaciones de contenido para los usuarios basándose en las preferencias individuales y los patrones de comportamiento colectivo.

La bnmf urp se centra en un enfoque basado en el usuario, considerando factores neutros que permiten mejorar la precisión de las recomendaciones al minimizar los sesgos en la información de entrada. En cambio, la técnica de epoch epoch en biasedmf bemf introduce iteraciones secuenciales que afinan el proceso de recomendación considerando sesgos inherentes, ajustando dinámicamente los pesos y preferencias sobre los datos.

La evaluación de estos modelos se basó en distintos conjuntos de datos de filtrado colaborativo y medidas de calidad más allá de la precisión tradicional, como la novedad y la diversidad de las recomendaciones. Los resultados mostraron que la implementación de estas técnicas permite una mayor adecuación a las necesidades de recomendaciones diversificadas y relevantes, mejorando la interpretabilidad de las recomendaciones gracias a una semántica más rica de los factores involucrados. Esta capacidad de proporcionar recomendaciones precisas y novedosas es fundamental para mejorar la experiencia del usuario y asegurar la reproducibilidad de los experimentos realizados.

Generating synthetic datasets for collaborative filtering recommender systems using generative adversarial networks

El texto aborda el campo de los sistemas de recomendación, destacando el uso de técnicas avanzadas como las redes generativas adversarias (GANs) para crear conjuntos de datos sintéticos que mejoren la filtración colaborativa. En este contexto, se discuten varios enfoques de filtración, específicamente la factorización de matrices (MF) y sus variantes.

Entre estas variantes, se mencionan dos técnicas: Bias-aware Matrix Factorization (BMF) y Unbiased Rating Prediction (URP). Estas técnicas son esenciales para abordar sesgos y mejorar la precisión de las recomendaciones al tener en cuenta las peculiaridades de los datos y los comportamientos del usuario. El método Epoch-Epoch en BMF proporciona iteraciones continuas para refinar los modelos una y otra vez, mejorando la precisión iterativa en las recomendaciones, mientras que el BiasedMF (BEMF) integra consideraciones de sesgos sistemáticos en los modelos de filtrado colaborativo.

La generación de conjuntos de datos sintéticos mediante GANs parametrizados, permite manejar la variabilidad estocástica dentro del modelo, creando un conjunto de datos representativo que potencia la precisión y relevancia de los sistemas de recomendación. Esto refleja una evolución en los modelos de filtrado colaborativo tradicionales hacia enfoques más sofisticados, impulsados por la inteligencia artificial y el aprendizaje profundo, para lograr una personalización más efectiva y precisa.

□Documento: Deep variational models for collaborative filtering-based recommender systems.pdf

El texto aborda cómo los modelos de filtrado colaborativo utilizados en sistemas de recomendación, específicamente aquellos basados en factorización matricial, están evolucionando con el uso de técnicas de aprendizaje profundo, como la Implementación de Factorización Matricial Profunda (DeepMF). Entre los modelos mencionados, destaca

la factorization no negativa bayesiana (BNMF), que ha sido popular en implementaciones anteriores. Sin embargo, la adopción de arquitecturas profundas, como DeepMF, ha mejorado la precisión y flexibilidad de estos modelos más allá de lo posible con enfoques tradicionales basados en aprendizaje automático.

Se resalta la técnica Deep Variational Model en el contexto de filtrado colaborativo y cómo introduce la estocasticidad en el espacio latente mediante codificadores automáticos variacionales. Esta técnica, que contribuye significativamente a un espacio estructurado y continuo, supera algunos de los desafíos del alto grado de esparsidad común en los sistemas de recomendación. Asimismo, la inclusión de técnicas variacionales y enriquecimientos variacionales ha demostrado resultados superiores.

En cuanto al conjunto más amplio de métodos de filtrado colaborativo reconocidos en el texto, se mencionan otras técnicas como la factorización matricial probabilística (PMF) y el clásico algoritmo k-NN, destacando cómo estas metodologías han sido evolucionadas por enfoques más robustos y precisos, como lo es DeepMF.

El texto aborda cómo los modelos de filtrado colaborativo utilizados en sistemas de recomendación, específicamente aquellos basados en factorización matricial, están evolucionando con el uso de técnicas de aprendizaje profundo, como la Implementación de Factorización Matricial Profunda (DeepMF). Entre los modelos mencionados, destaca la factorization no negativa bayesiana (BNMF), que ha sido popular en implementaciones anteriores. Sin embargo, la adopción de arquitecturas profundas, como DeepMF, ha mejorado la precisión y flexibilidad de estos modelos más allá de lo posible con enfoques tradicionales basados en aprendizaje automático.

Se resalta la técnica Deep Variational Model en el contexto de filtrado colaborativo y

cómo introduce la estocasticidad en el espacio latente mediante codificadores automáticos variacionales. Esta técnica, que contribuye significativamente a un espacio estructurado y continuo, supera algunos de los desafíos del alto grado de esparsidad común en los sistemas de recomendación. Asimismo, la inclusión de técnicas variacionales y enriquecimientos variacionales ha demostrado resultados superiores.

En cuanto al conjunto más amplio de métodos de filtrado colaborativo reconocidos en el texto, se mencionan otras técnicas como la factorización matricial probabilística (PMF) y el clásico algoritmo k-NN, destacando cómo estas metodologías han sido evolucionadas por enfoques más robustos y precisos, como lo es DeepMF.

Tópico: expert application and similarity measure in knowledgebased

□Documento: Recommender systems survey.pdf

El texto presenta una visión general de los sistemas de recomendación, centrándose en los enfoques basados en el conocimiento y la importancia de las medidas de similitud dentro de este contexto. Los sistemas de recomendación han evolucionado desde filtros colaborativos y basados en contenido hasta incorporar técnicas más avanzadas que utilizan información social y del Internet de las Cosas (IoT). En particular, las medidas de similitud son cruciales para mejorar la precisión de las recomendaciones, desempeñando un papel fundamental en las decisiones humanas mediante la evaluación de experiencias y conocimientos previos.

El documento discute cómo las medidas de similitud y los filtros colaborativos son clave en el desarrollo de recomendadores, proporcionando una base para técnicas híbridas que buscan aprovechar múltiples metodologías para mejorar la personalización y relevancia de las recomendaciones. Estas técnicas no solo se limitan a áreas clásicas como películas o música, sino que se extienden a campos diversos como aplicaciones de aprendizaje electrónico, comercio electrónico y búsquedas web.

A lo largo del documento, se enfatiza la evolución de estos sistemas, desde su uso en la web tradicional hacia su integración con la web social y, más recientemente, la inclusión de datos del IoT. Se destaca el papel de los métodos basados en el conocimiento en abordar desafíos como el arranque en frío y la escasez de datos, al incorporar conocimiento externo para mejorar la estabilidad y precisión de las recomendaciones.

El texto presenta una visión general de los sistemas de recomendación, centrándose en los enfoques basados en el conocimiento y la importancia de las medidas de similitud

dentro de este contexto. Los sistemas de recomendación han evolucionado desde filtros colaborativos y basados en contenido hasta incorporar técnicas más avanzadas que utilizan información social y del Internet de las Cosas (IoT). En particular, las medidas de similitud son cruciales para mejorar la precisión de las recomendaciones, desempeñando un papel fundamental en las decisiones humanas mediante la evaluación de experiencias y conocimientos previos.

El documento discute cómo las medidas de similitud y los filtros colaborativos son clave en el desarrollo de recomendadores, proporcionando una base para técnicas híbridas que buscan aprovechar múltiples metodologías para mejorar la personalización y relevancia de las recomendaciones. Estas técnicas no solo se limitan a áreas clásicas como películas o música, sino que se extienden a campos diversos como aplicaciones de aprendizaje electrónico, comercio electrónico y búsquedas web.

A lo largo del documento, se enfatiza la evolución de estos sistemas, desde su uso en la web tradicional hacia su integración con la web social y, más recientemente, la inclusión de datos del IoT. Se destaca el papel de los métodos basados en el conocimiento en abordar desafíos como el arranque en frío y la escasez de datos, al incorporar conocimiento externo para mejorar la estabilidad y precisión de las recomendaciones.

Tópico: proposed wganrs and architecture generate in wasserstein ganbas

documento: Wasserstein GAN based architecture to generate collaborative filtering synthetic dataset

El texto trata sobre la propuesta de una arquitectura basada en Generative Adversarial Networks (GAN) usando el principio de Wasserstein (WGAN) para la generación de datasets sintéticos en sistemas de recomendación. Estas WGAN-RS (Wasserstein GAN Recommender Systems) se enfocan en mejorar el rendimiento y precisión de dichos sistemas, proporcionando conjuntos de datos sintéticos que permiten simular diferentes escenarios. La arquitectura propuesta abarca la utilización de embeddings densos, continuos y cortos en un espacio latente, en lugar de muestras grandes y dispersas que eran características de modelos GAN anteriores. Esta técnica busca mejorar la representación de datos y reducir problemas como el "mode collapse", incrementando el tamaño y la diversificación de los datasets sintéticos, además de mantener una distribución adecuada de calificaciones.

La relevancia de estos sistemas de recomendación generativos radica en su capacidad para personalizar las sugerencias de productos o servicios, algo que es muy utilizado por empresas grandes como Spotify, Netflix o Amazon. Este enfoque basado en WGAN es especialmente importante en la medida en que puede generar perfiles sintéticos de usuarios, ayudando a incrementar el tamaño de los datos disponibles para el entrenamiento y prueba de sistemas de recomendación, permitiendo una mejor adaptación a las preferencias de los usuarios mediante la personalización de recomendaciones. La reproducibilidad de este enfoque está garantizada mediante el código abierto disponible en un repositorio de GitHub, lo que facilita la implementación y prueba.

El texto trata sobre la propuesta de una arquitectura basada en Generative Adversarial Networks (GAN) usando el principio de Wasserstein (WGAN) para la generación de

datasets sintéticos en sistemas de recomendación. Estas WGAN-RS (Wasserstein GAN Recommender Systems) se enfocan en mejorar el rendimiento y precisión de dichos sistemas, proporcionando conjuntos de datos sintéticos que permiten simular diferentes escenarios. La arquitectura propuesta abarca la utilización de embeddings densos, continuos y cortos en un espacio latente, en lugar de muestras grandes y dispersas que eran características de modelos GAN anteriores. Esta técnica busca mejorar la representación de datos y reducir problemas como el "mode collapse", incrementando el tamaño y la diversificación de los datasets sintéticos, además de mantener una distribución adecuada de calificaciones.

La relevancia de estos sistemas de recomendación generativos radica en su capacidad para personalizar las sugerencias de productos o servicios, algo que es muy utilizado por empresas grandes como Spotify, Netflix o Amazon. Este enfoque basado en WGAN es especialmente importante en la medida en que puede generar perfiles sintéticos de usuarios, ayudando a incrementar el tamaño de los datos disponibles para el entrenamiento y prueba de sistemas de recomendación, permitiendo una mejor adaptación a las preferencias de los usuarios mediante la personalización de recomendaciones. La reproducibilidad de este enfoque está garantizada mediante el código abierto disponible en un repositorio de GitHub, lo que facilita la implementación y prueba.